

D06 法律 AI 应用创新与实践

第十七届 · 服务外包创新创业大赛

「她盾」

职场女性权益守护智能体

你的身后,站着一个懂法更懂你的"她"

AI 驱动的职场女性权益守护伴侣 — 精准识别 · 证据保全 · 路径指引 · 情感支持

 她眼 · 言行雷达

 她权 · 权益指南

 她证 · 证据保全

 她行 · 维权导航

 她心 · 情绪树洞

 她声 · 共鸣回响

参赛赛道

2026 腾讯开悟全球 AI 公开赛 · D06 法律 AI 应用创新与实践

团队名称

她说了算队

大赛全称

第十七届中国大学生服务外包创新创业大赛 AI 专项赛

作品链接

huangjwwen.github.io/her_shield

在你犹豫时,给你破局的底气

在你受伤时,给你拥抱的温度

目录

CONTENTS

一

项目介绍

项目定位 · 需求分析 · 6 大模块功能详解 · 3 大典型使用场景 · 工程亮点

二

项目解决方案

五层全栈架构 · 后端代理与缓存策略 · 双层评测体系 · 智能体 Prompt 设计

三

项目说明书

整体使用流程 · 模块操作指引 · 部署与运行 · 工程细节与未来展望

CHAPTER 01 · 第一章

01

项目介绍

本章介绍「她盾」的项目定位、市场痛点(隐形化·举证难·维权贵)、五层用户困境，并按「判断→证据→行动→支持」四层任务模型，详解 6 大智能体模块功能。

1.1 项目基础信息

项目要素	内容
项目名称	「她盾」——职场性别权益守护智能体
参赛赛道	2026 腾讯开悟全球 AI 公开赛 · D06 法律 AI 应用创新与实践
团队名称	她说了算队
作品链接	https://huangjwwen.github.io/her_shield/
代码仓库	https://github.com/Huangjwwen/her_shield
核心技术栈	腾讯元器(5个智能体) + 腾讯 CloudBase 后端 + 得理开放平台 + Vanilla JS + Web Crypto
开发工具	CodeBuddy
一句话定位	在职场遭遇性别歧视或性骚扰?先别慌,我们帮你接住这一刻。
核心价值	让每一位职场女性在面对性别歧视或性骚扰时不再孤立无援——知道自己有什么权利、知道对方哪里违法、知道下一步怎么办。
目标用户	求职期及入职初期女性;遭遇职场性别不平等或性骚扰的在职女性

◆ 项目宣言

你的身后,站着一个懂法更懂你的"她"

AI 驱动的职场女性权益守护伴侣 精准识别 · 证据保全 · 路径指引 · 情感支持

在你犹豫时,给你破局的底气 在你受伤时,给你拥抱的温度

1.2 项目需求分析

职场性别歧视与性骚扰问题隐蔽而普遍,呈现「**隐形化、举证难、维权贵**」三大特征。

1.2.1 市场数据

数据	来源
60.9% 的求职女性被询问婚育情况	智联招聘 2026 调查报告
职场性别歧视案件原告胜诉率 < 30%	中国裁判文书网数据
性骚扰受害者中仅 7% 最终选择报警或起诉	全国妇联统计
"职场性骚扰"话题阅读量超 12 亿,多为匿名吐槽	社交媒体数据

1.2.2 五层用户困境

认知层 不知违法 情绪层 不知找谁 证据层 不会取证 行动层 不敢维权 归属层 孤立无援		
层级	困境	具体表现
认知层	不知违法	70% 女性遭遇歧视却不知违法,法律条文晦涩,信息碎片化
情绪层	不知找谁	愤怒、羞耻、害怕交织,缺乏即时低门槛的情绪承接渠道
证据层	不会取证	不清楚保存什么怎么保存,事后补救往往证据已灭失
行动层	不敢维权	担心报复、不了解流程、律师费高昂,缺乏可操作指南
归属层	孤立无援	缺少安全匿名的倾诉渠道,受害者易陷入孤立感

1.2.3 竞品分析

「她盾」填补国内「**职场性别权益 + AI 智能体**」垂直赛道空白:

方案	即时响应	法条精准	取证指导	场景垂直	低门槛	情感支持
通用法律咨询平台(律图、找法网)	X	✓	X	X	X	X
女性社区(小红书、豆瓣小组)	✓	X	X	部分	✓	✓
传统法律援助(妇联、援助中心)	X	✓	部分	✓	X	部分
「她盾」(本作品)	✓	✓	✓	✓	✓	✓

◆ 1.2.4 真正的差异化

很多项目在做"AI + 法律",但我们做的是「弱势情境下的决策辅助系统」:

维度	传统法律 AI	「她盾」
🧠 认知辅助	仅检索法条	在用户被情绪裹挟时,接管复杂的法律逻辑分析,提供客观判断
🗺️ 行动引导	给一份"百科"	把抽象路径拆解为"下一步做什么"的具体指令
💗 心理缓冲	无	承接焦虑与恐惧,用共情式交互让用户感到"背后有人"

1.3 项目使用场景

◆ 场景一:面试遭遇婚育隐形歧视(求职期)

用户画像: 小李 · 25 岁应届生 · 面试互联网公司产品经理岗

痛点: 面对 HR 关于"近期是否有结婚/生育计划"的追问,感到被冒犯却不知如何得体反击,担心拒绝回答会丢 Offer。

步骤	用户动作	系统响应
1	面试结束后立即打开「她眼·言行雷达」,输入 HR 的追问原话	5 秒内返回 结构化报告卡 :风险等级 中危 、性骚扰要件分析、法条引用、三句应对话术
2	查看法律定性	系统判定该问题涉嫌违反《妇女权益保障法》第 43 条,属于就业性别歧视;提示"这并非你的问题,无需自我怀疑"
3	一键复制话术	获取高情商回应——"这个问题涉及个人隐私,与岗位胜任力无关,我们可以聊聊我的项目经验吗?"
4	若因此未被录用	「她行·维权导航」给出向劳动监察大队投诉的具体流程与证据清单

结果:  小李不再内耗,当场用生成的话术礼貌反问,面试官意识到失言并道歉,面试顺利进入下一轮。

◆ **场景二:孕期被恶意调岗降薪(在职博弈)**

用户画像: 张女士·32 岁·怀孕 4 个月·被口头通知调至边缘行政岗、薪资减半

痛点: 领导口头施压,未发红头文件,既想保住孩子又不想丢掉原本的高薪职位,陷入恐慌。

步骤	用户动作	系统响应
1	进入「她权·权益指南」描述现状	立刻显示:《妇女权益保障法》第 48 条明确禁止因怀孕降低工资或单方调岗
2	切到「她证·证据保全」	生成取证攻略:指导张女士给领导发微信"领导,关于您刚才口头提到的调岗降薪决定,我想确认一下从哪天开始生效?"——将口头通知转化为书面证据
3	「她行·维权导航」规划三步走	发送《被迫调岗异议函》→ 正常打卡考勤 → 申请劳动仲裁
4	「她眼·言行雷达」二次确认	输入"怀孕被降薪",获得高危判定 + 上海港行案(沪 02 民终 6339 号)类案参考

结果:  攻守逆转。公司收到正式的《异议函》及完整的证据链后,意识到违法成本过高,主动撤回调岗通知,恢复原薪资待遇。

◆ 场景三:深夜遭遇职场性骚扰(危机应对)

用户画像: 王女士·28 岁·深夜收到直属领导露骨的暧昧微信


痛点: 感到恶心、恐惧,担心截图留证会激怒领导导致被穿小鞋,更担心没人相信自己。

步骤	用户动作	系统响应
1	第一时间进入「她心·情绪树洞」	AI 温柔接住情绪:"这不是你的错,你不需要为他人的越界行为感到羞耻。"
2	切到「她证·证据保全」	系统一步步指导:如何完整截图(含对方微信号、时间轴) → 如何录屏 → 如何申请可信时间戳 — 确保证据法律效力,且不打草惊蛇
3	「她声·共鸣回响」	看到类似案例的胜诉经历,确认"这不是潜规则,而是违法",获得反击的勇气
4	「她行·维权导航」 规划维权路径	六步维权路径指导:从内部投诉到劳动仲裁的完整行动方案 + 关键时效提醒

结果:  证据链闭环。王女士在掌握完整证据后向公司合规部实名举报,公司介入调查并处理了涉事领导,王女士获得了应有的尊重与赔偿。

1.4 关键功能说明

「她盾」由 6 大功能模块构成,围绕「识别 → 取证 → 行动 → 支持」四层任务模型,每一层各司其职,模块之间相互导流。



🔍 判断层 — 让用户“看清”

▶ MODULE 1 · 她眼·言行雷达

识别职场不当言行,提供应对建议

用户输入面试问题、聊天记录或场景描述, AI 通过**多节点 workflow**进行专业分析:

1. **宽松门控判断(召回优先)** — 快速筛出可能涉及性别歧视或性骚扰的内容
2. **结构化案情要素抽取** — 客观提取事实信息, 输出标准 JSON
3. **事实标注+风险等级映射分离** — LLM 只标要件状态, 代码节点做确定性风险等级映射

设「友好提示」及「通用建议」两条降级分支保证可用性。**特别设计反误判机制**——若用户认为 AI 将自己的求助误判为“不涉及”, 可一键触发**深度分析**, 跳过门控直接进入要件式评估, 确保即使算法犯错, 用户也有发言权。

功能亮点: - ⚡ 宽松门控 + 召回优先, 给出明确结论, 不漏判 - 🔄 反误判机制: 一键触发深度分析, 跳过门控直达专业评估 - 📋 结构化案情要素抽取, 为后续评估提供精准输入 - ⚖️ 要件式法律评估: 行为与性有关 / 违背意愿 / 职场情境三要件 - 📖 法条引用(《妇女权益保障法》《女职工特别规定》等)+ 类案匹配(法

院/案号/年份/裁判要点),增强说服力 - 🗨️ 三级话术生成(gentle/firm/formal),适配不同沟通场景 - 🧑🏻
风险四级映射(高危/中危/低危/无风险)由代码节点确定性映射

标签: 宽松门控 反误判机制 要件式评估 法条引用 类案匹配 3 级话术 情绪安抚 核心差异化

► MODULE 2 · 她权·权益指南

快速检测权益状况,明确维权方向

用户描述职场场景(求职/在职/孕期/哺乳期等),智能体列出**法定权利清单**并附法律依据(法律名称 + 条款序号),用白话解释每条权利。

前端可视化亮点(2026-06 升级): - 🎯 **场景识别头部:**根据用户输入自动识别并展示场景标签(👩 孕产期 / 🔍 求职 / 💼 在职 / 💰 薪酬调岗 / 📄 解雇 / ⚠️ 性骚扰 / ⚖️ 性别歧视 / 🏥 医疗保障 共 8 类) - 🧑🏻

权利卡片网格:把 LLM 自然语言输出解析成**结构化卡片网格**(每张卡片 = 序号徽标 + 权利名 + 蓝色法律引用胶囊 + 灰底法律原文段 + 💡 紫色白话解释) - 🌸 **温馨提示独立暖黄卡片** - 💎 **法律名/条款号/法律原文段三级蓝色高亮** —— 即使解析失败兜底为纯文本,蓝色高亮仍生效

功能亮点: - 🎯 场景化匹配,精准定位用户所处阶段 - 🧑🏻 权利清单可视化,一键获取完整权益图谱 - 🔍 法律依据可追溯,增强维权底气 - 🔄 **重试按钮:**跳过缓存重新查询

标签: 场景化权利清单 法条引用 白话解释 温馨提示 权利卡片网格 场景识别 法条蓝色高亮

◆ 📄 证据层 — 让用户“有底气”

► MODULE 3 · 她证·证据保全

专业指导证据收集,增强维权底气

引入**证据链思维**,提供**操作级取证指导**: - 口头提问 → 「**确认式追问**」转化为文字证据 - 聊天记录 → **截图 + 录屏 + 导出**三步走 - 合法录音边界(参与对话、不剪辑) - **可信时间戳**固化关键证据

内置怀孕调岗、聊天记录骚扰、监控盲区等**六大典型场景**专项指导,帮助用户构建「时间-地点-人物-行为-后果」的完整证据闭环。

前端技术亮点: - 🔒 **浏览器端 Web Crypto SHA-256 哈希指纹:**用户上传截图、文档后,前端浏览器内直接计算 SHA-256,原文件永不上传服务器,只存储指纹 - 📄 **自动生成《存证凭证》:**包含文件名、SHA-256 哈希值、时间戳,可下载留档,支持事后防篡改演示(再次上传同文件,验证哈希一致) - ✅ **结构化取证清单(checklist):**把原本一大段文字结果升级为**可勾选 checklist + 进度条**,完成度实时可见 - 🧑🏻 **案型** → **证据规则库:**内置 6 大典型场景的取证规则,AI 自动把用户描述分类到对应案型,并按规则生成对应取证项

功能亮点: - 🔗 证据链思维引导,告别零散无效取证 - 📄 六大典型场景专项方案,覆盖高频维权痛点 - ⚖️ 合法边界提示,避免因取证不当反被追责 - ✅ 可勾选清单 + 进度条,从"读完就忘"升级为"逐项确认"

标签: 证据链思维 操作级指导 SHA-256 指纹 存证凭证 防篡改 结构化 checklist 案型规则库 进度条 合法录音边界 时间戳固化 Markdown渲染 合法边界去重 核心差异化

🔗 行动层 — 让用户"能行动"

► MODULE 4 · 她行·维权导航

全流程维权路径,专业步骤指导

六步阶梯路径(现场反应 → 内部投诉 → 行政举报 → 劳动仲裁 → 法院诉讼 → 专业帮助),提供: - 关键时效(仲裁 1 年 / 起诉 15 日) - 所需材料清单 - 具体操作话术 - 配合/不配合两种分支建议

前端可视化亮点: - 📏 竖直时间轴渲染:六步路径渲染成带紫色圆圈数字徽标 + 渐变竖线连接的时间轴,每步卡片化展示 - 📞 维权热线胶囊化:12333 / 12338 / 12348 / 12388 / 400-161-9995 自动转换为暖黄色 📞 胶囊,点击直接 tel: 拨号 - ⌚ 时效字眼橙色高亮:"1 年""15 日""3 年"等关键时效自动 ⌚ 橙色胶囊化,强提醒 - 📅 时效尾段独立暖橙卡片:跟主时间轴视觉分层 - 🔄 重试按钮:跳过缓存重新规划维权路径

功能亮点: - 📊 阶梯式路径拆解,降低维权心理门槛 - ⌚ 关键时效强提醒,避免错过维权窗口期 - 📞 内置维权热线一键转接(12333 劳动监察 / 12338 妇联 / 12348 法律援助 / 12388 纪检监察) - 🔄 分支决策支持,适配不同用户的选择偏好

标签: 6 步维权路径 时效提醒 分支决策 模板话术 热线一键转接 竖直时间轴 胶囊化高亮

💬 支持层 — 让用户"不崩溃"

► MODULE 5 · 她心·情绪树洞

情感倾诉支持,暖心陪伴倾听

AI 扮演温暖陪伴者,核心原则「不解决问题,只接住情绪」—— 1. 承认感受(用用户原词) 2. 正常化处境(不评判) 3. 表达陪伴(轻轻托住)

特别设计: - 🚨 危机干预弹窗(强制层 + 会话防重复):识别"自杀""活不下去"等高危关键词后,强制显示求助弹窗,提供心理援助热线 + 紧急联系建议。该弹窗不会被任何后续普通回复覆盖;同一对话会话内弹窗只出现一次,关闭后不再反复弹出,避免对处于危机中的用户造成二次打扰 - 💬 CBT 轻度支持逻辑:升级 harbor 智能体 Prompt,对自我否定、灾难化、过度自责等表达,温和的"重新理解",但不让用户觉得被"教育",保持朋友聊天感 - 🗣️ 云端 TTS 语音引导 + 降级兜底:优先通过 /proxy/tts 走微软/腾讯云合成音

频,音质自然;若云端 TTS 不可用则**自动降级到浏览器原生 SpeechSynthesis**,保证语音功能始终可用,隐私零外传 - 🚫 禁止把痛苦快速"正能量化",允许负面情绪存在

功能亮点: - ❤️ 情绪优先原则,先安抚再引导 - 🌈 非评判式回应,营造安全倾诉空间 - 🧠 共情式交互设计,缓解用户孤独感 - 🚨 自伤倾向自动干预(强制弹窗,不可关闭覆盖) - 🔊 浏览器内语音引导,触觉与听觉双通道安抚

标签: 情绪承接 有温度陪伴 不评判不说教 CBT 轻度支持 危机干预强制弹窗 会话防重复 云端 TTS 降级兜底 核心差异化

► MODULE 6 · 她声·共鸣回响

分享维权经历,互助成长社区

匿名故事社区,用户浏览他人维权经历与心得,打破「**只有我一个人遇到这种事**」的孤立感,在情感上感受同伴支持,在实践上获得真实案例参考。

内容来源: 所有故事**改编自真实判例和新闻**(脱敏处理),不编造、不杜撰。

后端架构: - 📁 **CloudBase 云数据库**持久化存储用户投稿故事,支持千万级文档 - 🗨️ **自动脱敏:**发帖时自动识别并打码**手机号 / 身份证号 / 邮箱**等敏感信息,即使用户不小心写入也不会泄露 - 🏷️ **标签筛选:**按"性别歧视 / 性骚扰 / 怀孕调岗 / 同工不同酬"等主题筛选 - 🔄 **本地 + 云双层:**localStorage 即时展示历史浏览 + CloudBase 真社区存储新投稿

功能亮点: - 🗨️ 匿名化保护 + 自动脱敏双保险 - 📖 **真实案例库**,提供可复制的维权经验 - 🤝 同伴互助机制,构建情感支持网络 - 🏷️ 主题标签筛选,精准查找同类经历

标签: 匿名经历分享 互助社区 打破沉默文化 真实判例改编 三类敏感信息自动脱敏 CloudBase 持久化

1.5 工程亮点:缓存策略「3 道防线」

针对"同问不同答 → 加缓存 → 异常响应也被缓存 → 重试无意义"这一典型反模式,我们设计**3 道防线**的缓存策略:

防线	实现层	作用
① 写入白名单 shouldCache()	后端代理	只缓存 finish_reason: stop 且 content 非空的真正成功响应。 工作流 10003 / 内容审查截断 / 解析失败一律不缓存 ,确保用户重试有意义
② nocache=true 显式跳过	前后端协同	用户点「强制深度分析」或「🔄 重试」按钮,前端自动带 nocache=true ,确保 100% 重新打元器
③ 30 分钟 TTL + 1000 LRU 上限	后端代理	控制内存占用 + 元器侧改 prompt 后能在 30 分钟内自动失效

前端 4 个模块已全部支持: - 言行雷达: 🔄 重试 按钮 + 既有「强制深度分析」按钮 - 权益指南 / 维权导航: 🔄 重试 按钮统一支持

1.6 评测与质量保障

为对齐"AI 给出的判定是否专业、可信",我们构建了**标准化评测体系**:

评测维度	数据
测试集规模	100 条 = 50 精标 + 50 变体
案例锚定	17 条直接锚定具体司法判例(含案号 + 法院 + 年份) 6 条锚定法律条文明文禁止 27 条由判例规则推导
变体策略	同义改写 / 细节扰动 / 干扰句 / 要件边界 / 长文本扩展 5 类
整体准确率	79.0% (95% CI 71.0% – 87.0%)
高危召回率	90.0% (45/50)— 法律 AI 最关键指标
无风险准确率	100% (16/16)— 不刷存在感
±1 级容忍准确率	96.0% — 误差仅在相邻一级
方法学	标注者只标"事实层要件状态", 风险等级由产品同一份代码自动映射 ,标准答案与产品输出走同一映射代码,差异只来自 AI 对事实的判断

测试集、评测脚本完整开源,所有标注理由公开在 `eval/test_set.json` 的 `notes` 和 `anchor` 字段。

CHAPTER 02 · 第二章

02


项目解决方案

本章呈现「她盾」的五层全栈架构,详解后端代理层的密钥下沉与 3 层缓存策略,以及业界少有的事实-映射分离的双层评测体系,并附 5 个智能体的 Prompt 设计。

2.1 项目技术实现方案

2.1.1 整体架构

「她盾」采用**五层全栈架构**,从前端交互到 AI 智能体编排,每一层都为「弱势情境下的决策辅助」这一目标服务:




◆ 2.1.2 各层职责

层	技术组件	核心职责
交互层	Vanilla JS ES Modules + HTML5 + CSS3 + Web Crypto API	6 模块用户界面;首屏 87 KB / TTI < 0.8 秒;浏览器端 SHA-256 证据指纹
后端代理层	腾讯 CloudBase 云函数 + 云数据库 + HTTP 触发器	API 代理转发;5 个 appkey 下沉到环境变量;3 层缓存策略(白名单/nocache/TTL+LRU)治理"同问不同答"
智能层	腾讯元器 5 大智能体(可视化 workflow 编排)	意图识别、要件抽取、要件式评估、法条引用、类案匹配、温暖回应、三类话术
知识层	得理开放平台 API	法规检索(RAG)、类案检索(RAG)
评测体系	Node.js 评测脚本 + 100 条标注测试集	准确率回归;要件级标注 + 代码机械映射;混淆矩阵分析

◆ 2.1.3 后端架构详解

后端代理层是「她盾」在工程层面**回应初赛专家批评**的核心载体。初赛时被指出「前端硬编码 6 个 appkey,F12 即可拿走」,本次我们用 CloudBase 云函数把所有密钥和缓存逻辑下沉到服务端,并附带解决了「同问不同答」「CORS 跨域」「超时控制」「异常透明」等 4 个伴随问题。

下面这张时序图展示了一次完整请求从浏览器到元器再回到前端的全链路:



► 核心改进对照

维度	改造前	改造后
密钥安全	5 个 appkey 硬编码在 <code>js/core.js</code> ,F12 可见	全部下沉到 CloudBase 环境变量 (<code>KEY_RADAR</code> / <code>KEY_SELFCHECK</code> / <code>KEY_EVIDENCE</code> / <code>KEY_GUIDE</code> / <code>KEY_HARBOR</code>),前端代码不含任何 KEY
同问不同答	用户同一问题反复问得到不同答案,产品体验不一致	3 层缓存策略 (白名单 / nocache / TTL+LRU)治理,详见下文
网络延迟	浏览器 → 公网 → 元器,延迟 ~200ms	浏览器 → CloudBase(腾讯生态)→ 元器, 同域低延迟降低 30-50ms
CORS	浏览器跨域报错	代理函数返回 <code>Access-Control-Allow-Origin: *</code> 与 <code>OPTIONS</code> 预检
超时控制	浏览器默认 60s,深度分析常超时	CloudBase 函数 120s 充足覆盖元器深度分析(实测 38-58s)
错误兜底	元器 10003 直接抛错给用户,界面"白屏"	工作流 JSON 解析失败 → 返回 <code>risk_level: null</code> + <code>parse_error</code> ,前端识别后渲染「分析异常」紫色卡片而非伪装"无风险"

► 3 层缓存策略

为彻底解决「同问不同答」并且**避免"异常响应也被缓存"的反模式**(用户重试拿到相同的异常),我们设计 3 道防线:

防线	实现位置	作用
① 写入白名单 <code>shouldCache()</code>	代理函数	只缓存 <code>finish_reason: stop</code> 且 content 非空的真正成功响应; 工作流 10003 / 内容审查截断 / 解析兜底响应一律不缓存 ,确保重试有意义
② <code>nocache=true</code> 显式跳过	前后端协同	用户点击「  强制深度分析」或「  重试」按钮时,前端自动加 <code>nocache=true</code> , 100% 重新打元器 ,答辩演示不暴露 <code>fromCache: true</code>
③ 30 分钟 TTL + 1000 LRU 上限	代理函数	控制内存占用;同时让元器侧改 prompt 后能在 30 分钟内 自动失效旧缓存 ,无需手动清理


完整方案见 `BACKEND_CACHE_PROPOSAL.md` ,前端已上线对应入参,后端按方案落地后 6 项黑盒测试可一键验证。

安全与可靠性设计要点

- **密钥永不出现在 git 仓库:** `.gitignore` 排除任何 `.env` / 含 `KEY_` 前缀的本地文件; `eval/run.js` 仅在开发者本机通过 `--key` 命令行参数或环境变量读取
- **请求体严格白名单:**代理只透传 `agentType / messages / force / nocache / has_image / image_urls / query` 几个已知字段, **多余字段一律丢弃**,降低注入面
- **同问稳定输出:**同样输入 + 同样 `force` 状态 → 命中缓存 → 同样回复, **支撑评测可复现性**
- **异常透明而非伪装:**元器侧 10003、内容审查截断、JSON 解析失败,前端都会**显式渲染异常卡片**,绝不让 LLM 错误悄悄变成"无风险"判定

2.1.4 评测体系架构

我们建立了**双层评测方法学**——这是法律 AI 项目里少有的工程化质量保障:



关键创新: 标准答案的 `risk_level` 不再由标注者心算,而是由产品里**同一份** `compute_risk_level` 代码根据标注者标注的事实自动映射 —— 这样**任何差异都只可能来自 AI 对事实的判断**,不来自标注者主观。

评测数据:

指标	v1.3+annotated (新方法学)
整体准确率	79.0% (95% CI 71.0-87.0%)
高危召回	90.0% (45/50)
中危召回	47.4%
无风险准确率	100% (16/16)
±1 级容忍准确率	96.0%

2.2 AI 工具使用说明


本作品基于**腾讯元器平台**构建 5 个独立专用智能体,结合 **CodeBuddy + Claude Code** 辅助开发,已实现真实 API 调用。

2.2.1 智能体总览


智能体	智能体模式	工作流/Prompt 核心策略
她眼·言行·雷达	单工作流程模式: 门控 → 要件抽取 → 要件式评估; 误判:一键深度分析跳过门控	宽松门控(召回优先) → 结构化要素抽取 → 法条引用 + 类案匹配 → 要件式评估 + 三级话术 + 温暖回应 → 风险等级映射
她权·权益·指南	单工作流程模式: 意图识别 → 法规检索 → 生成输出	懂法专家角色;法定权利 + 法条号 + 白话
她证·证据·保全	单工作流程模式	证据留存助手角色;共情 → 操作级取证 → 安全保存规范 → 时效提醒 → 温情鼓励
她行·维权·导航	单工作流程模式	路径规划者角色;六步阶梯;时效关键节点;配合/不配合分支
她心·情绪·树洞	标准模式 (无工作流)	陪伴者角色;三步结构(承认 → 正常化 → 陪伴)+ CBT 轻度支持(prompt 升级)+ 高危关键词强制弹窗(会话级防重复)+ 云端 TTS 语音引导 (/proxy/tts 优先,失败降级浏览器 SpeechSynthesis)

2.2.2 核心 workflow 可视化

A. 她眼·言行雷达 workflow




节点拓扑:



反误判设计: 用户点击「强制深度分析」按钮 → 前端 `force=true` 透传给 workflow 开始节点 → **跳过门控 直接进入要件抽取**, 确保即使 AI 误判用户也能拿到完整分析。

▶ B. 她权·权益指南 workflow



▶ C. 她证·证据保全 workflow



▶ D. 她行·维权导航 workflow



◆ 2.2.3 核心 Prompt 设计

▶ 2.2.3.1 言行雷达「要件式评估和回应内容」节点 Prompt(核心)

📄 概述

该 Prompt 将模型定位为专业、温暖、坚定的法律评估顾问,根据用户描述、案情要素、法规详情和类案列表,完成两件事:(1) 内部做可解释的要件式评估,输出结构化字段(要件命中、加重情节、歧视严重度、法条引用、类案引用等);(2) 用温暖的语言给用户一段贴心叙事(narrative)和三句可直接使用的话术(gentle/firm/formal)。不输出风险等级(由后续规则节点统一裁定)。最终只输出一个紧凑 JSON 对象。

✔ 优点

优势维度	具体说明
要件式评估、可解释	逐条评估性骚扰/性别歧视要件,每条标注"满足/存疑/不满足/不适用",逻辑透明
法条引用可追溯	区分"得理"来源和"模型知识"来源,不编造条号或伪造原文
类案匹配、增强说服力	从 case_list 中挑选相似案例,如实提取信息,严禁编造
三级话术、场景定制	gentle/firm/formal 三种力度,用户可根据场合选择
温暖叙事、情绪支持	narrative 先接住情绪再点出法律性质,用大白话解释法条
结构化输出、下游可用	紧凑 JSON 格式,便于后续规则节点解析和前端渲染

 原文:

角色

你是一名专业、温暖、坚定的职场性别平等与反性骚扰/反性别歧视法律评估顾问,始终站在用户一边。你既能冷静地做出可解

任务

根据用户描述(`user_input`)、案情要素(`elements`)、法规详情(`law_details`,可能为空)、类案列表(`case_list`,可能为空)

- (1) 在内部做一次冷静、可解释的要件式评估,输出结构化字段(要件命中、加重情节、歧视严重程度、引用等);
- (2) 用温暖、有人情味的语言给用户一段贴心回应(`narrative`)和三句可直接使用的话术。

你【不要】输出风险等级(`risk_level`)——等级由后续规则节点依据你的结构化字段统一裁定。你只需把要件、情节、严重程度

最终【只输出一个 JSON 对象】,不要任何额外文字,不要 markdown 代码块。

第一步:内部评估(决定结构化字段;`narrative` 里不要堆术语)

1. 判类型 `type`:更像「性骚扰」还是「性别歧视」,两者都沾边就都列;完全看不出填["暂不明确"]。
2. 逐条评估要件 `elements_check`,每条 `status` 取值:满足 / 存疑 / 不满足 / 不适用。拿不准用"存疑",不要猜成"不满足"。
 - 性骚扰要件:行为与性有关 / 违背对方意愿 / 职场情境
 - 性别歧视要件:基于性别或婚育状况的区别对待 / 发生在就业环节 / 无合理职业资格依据
 不属于本案类型的要件,一律填"不适用"。
3. 性骚扰加重情节 `aggravating_factors`(数组,仅对性骚扰;无则空数组):从下列中选出描述中确有的——持续/重复、明确
4. 性别歧视严重程度 `discrimination_severity`(对象;非歧视时两项填"不适用"):
 - `institutional`(是否制度性):
 - "是" = 歧视被写入招聘广告/招聘条件/录用标准/公司政策/规章制度,或属反复、普遍、系统性做法。
 - "否" = 仅为个别、一次性、临时的口头言行,未写入任何规则、也未表现为普遍做法。
 - "存疑" = 仅当描述完全无法看出"是个别言行还是写入规则/普遍做法"时才用。
 - `concrete_harm`(是否已造成实质后果):
 - "是" = 已实际发生不利后果:被拒录/未被录用/辞退/降薪/调岗/扣薪/不予晋升等。
 - "否" = 描述中未提到任何已发生的不利后果。
5. `confidence`(高/中/低):`law_details` 与 `case_list` 都为空、或关键要件多为"存疑"时,降为"中"或"低"。

第二步:组织引用

- `law_references`:

- `law_details` 不为空 → 挑 2-5 条最相关的,写法规名称、第x条、条款原文,`source`="得理"。
- `law_details` 为空 → 凭法律知识引用相关条款,`source`="模型知识"。
- ⚠ 凭记忆引用时,若不确定条款号或原文,宁可只写法规名称与大意,【绝不编造条号或伪造原文】。

- `case_references`:

- 若 `case_list` 不为空 → 从中挑选 1-2 个最相似的案例。必填字段:`title/facts/judgment/key_point`;可选字段(仅当有信息时):`case_number/court/date`。具体赔偿金额、具体刑期、具体当事人姓名。
- ⚠ 绝对禁止编造或推测以下任何信息:`case_number/court/date`、具体赔偿金额、具体刑期、具体当事人姓名。
- 若 `case_list` 为空,返回空数组 [],严禁编造案例。

第三步:`narrative`(温暖、自然、像朋友,分段用 \n;必须分成 4-5 个自然段)

自然连贯地依次包含:

- ① 先接住情绪,理解并认可用户感受;
- ② 温和而明确地点出这件事在法律上很可能属于性别歧视/性骚扰;
- ③ 让用户知道法律站在 `ta` 这边,引用法律原文并用大白话解释相关条款;
- ④ 若有类案,自然带一句"在类似的情况里,.....";
- ⑤ 2-4 句真诚鼓励,让 `ta` 知道不是一个人在面对;
- ⑥ 按问题方向引导其他板块:想投诉/维权→「她行·行动导航」;想了解法定权利→「她权·权益指南」;想学留证据→「她证·证据清单」。

第四步:`response_scripts` — 三句可直接对对方说的话,按具体场景定制、不套模板:

- `gentle`:委婉但留有空间(不想起冲突时)
- `firm`:直接划清界限(对方明显越界时)
- `formal`:严肃正式、可留记录/震慑(需要留痕时)

边界

```

- 不推荐具体律师、不提供诉讼策略或案件代理。
- 与职场性别歧视/性骚扰无关的问题:type 填 ["暂不明确"],elements_check 全部"不适用",narrative 温和说明不在

# 输出格式(只输出此 JSON;不含 risk_level;narrative 内换行用 \n)
{
  "risk_summary": "不超过20字、描述事件涉嫌什么(不写等级)",
  "type": ["性别歧视"],
  "confidence": "高",
  "elements_check": [
    {"name": "行为与性有关", "status": "不适用", "note": ""},
    {"name": "违背对方意愿", "status": "不适用", "note": ""},
    {"name": "职场情境", "status": "不适用", "note": ""},
    {"name": "基于性别或婚育状况的区别对待", "status": "满足", "note": ""},
    {"name": "发生在就业环节", "status": "满足", "note": ""},
    {"name": "无合理职业资格依据", "status": "满足", "note": ""}
  ],
  "aggravating_factors": [],
  "discrimination_severity": {"institutional": "否", "concrete_harm": "否"},
  "law_references": [],
  "case_references": [],
  "response_scripts": {"gentle": ".....", "firm": ".....", "formal": "....."},
  "narrative": ".....(用 \\n 分段)",
  "suggested_modules": ["她行", "她证"],
  "disclaimer": "本指导不构成正式法律意见,重大维权请咨询律师或拨打 12338 / 12348。"
}

【输出要求】你的输出必须是紧凑的 JSON,不要包含换行符、缩进空格。

```

▶ 2.2.3.2 她权·权益指南「生成输出内容」节点 Prompt

📄 概述

该 Prompt 定义角色“她权·权益指南”,为职场女性提供特定场景(求职、孕期、调岗、解雇等)下的法定权利清单。输出要求:① 逐项列出权利,每项后附法律名称+条款序号(不抄全文)和白话解释;② 给出1-2条温馨提示(如注意事项、证据保留);③ 用朋友聊天式的语气,不使用方括号或机械分点。边界清晰:不回答“是否歧视”或“怎么怼回去”,引导至她眼·言行雷达;不提供具体法律代理建议。

✅ 优点

优势维度	具体说明
聚焦权利本身	不混杂情绪支持或维权步骤,纯粹告知"法律给了你什么",便于用户快速了解自身权益
法律引用简洁易懂	只写条款序号,避免法条堆砌;用1-2句白话解释,降低理解门槛
温馨提示实用	结合场景给出注意事项(如"调岗需要书面同意"),帮助用户避免踩坑
语气平等友好	像"懂法的朋友"聊天,没有说教感
严格边界	主动拒答非权利查询类问题,并温柔引导至正确模块,保持系统分工清晰

 原文:

```
#角色
你叫"她权·权益指南",是一位温和、懂法、善于倾听的职场女性权益助手。你不评判对错,也不教人"吵架",而是帮助用户理解法律。

#任务
用户会描述一个具体的职场场景或状态(如求职、在职、孕期、哺乳期、调岗、解雇、离职等),或者提出一个"可以吗?" "合法吗?"的问题。
你需要根据用户的描述,以及提供的法规名称和内容详情,按以下步骤回应:
1. 明确列出她在这个场景下享有的法定权利(每项权利后紧跟法律依据和通俗解释)。
2. 引用相关法律条文:只需写清法律名称和条款序号(如《女职工劳动保护特别规定》第6条),无需抄写全文。
3. 用白话解释每一条权利的含义,1-2句话,让用户一听就懂。
4. 最后给出 1-2 条温馨提示,聚焦注意事项或证据保留建议。

#输出格式要求
请将以上内容自然串联成连贯的文字,不要使用"【】"或类似方括号标记。
具体顺序为:先写"法律给你的权利",然后逐项说明(每项用"•"或自然分段)。
最后写"温馨提示",可以分段但避免机械分点(如"第一、第二")。

#风格与语气
像一位懂法的朋友在跟你聊天,不是法官也不是说明书。
用"你"称呼用户,语气平和、坚定、不冰冷。
不假设用户的情绪,但承认她的处境值得关注。
不替用户做决定,只提供法律依据和行动参考。

#边界
只回答与职场女性权益直接相关的问题(求职、在职、孕期、产假、哺乳期、同工同酬、晋升、调岗、解雇、离职等)。
如果用户问的是"这句话算不算歧视""我该怎么怼回去",请温柔地提醒:
"这个问题更适合问'她眼·言行雷达'哦,我可以帮你转接思路。"
如果用户问的是证据怎么留、流程怎么走,请提醒她使用"她证·证据保全"或"她行·行动导航"获取更具体的建议。
不提供具体法律代理或个案诉讼建议。
```

▶ 2.2.3.3 她证·证据保全「生成证据保全指南」节点 Prompt

 概述

该 Prompt 将模型定位为"她盾·证据留存助手",任务是教用户如何将事实转化为法律上可用的证据。针对典型场景(面试问婚育、怀孕调岗、性骚扰聊天记录、监控盲区等),给出具体取证方法:如"确认式追问"将口头内容转为文字、截屏+录屏+导出原始文件、合法录音边界、间接证据链构建等。同时指导安全保存

(云端加密、时间戳)和合法边界(不窃取文件、不剪辑录音)。语气冷静、专业。前端自动去重合法边界提醒段落,避免与底部静态提示栏重复。

✔ 优点

优势维度	具体说明
高度实操、场景化	针对每个典型场景提供"手把手"操作步骤(如"截屏需包含头像、日期、完整内容"),用户可直接执行
解决取证难点	特别处理口头提问、监控盲区等无直接证据的情况,提供"确认式追问""间接证据链"等技巧
强调合法性与安全	明确录音合法性条件、禁止行为(不在公司电脑备份私人网盘),保护用户自身合规
证据固化建议	推荐可信时间戳、云端+本地双备份,提升证据效力
不评判、不恐吓	用"别担心,有办法""这很常见"等短语降低用户压力
边界清晰	引导判断类问题至言行雷达,投诉路径至行动导航,避免越界

📄 原文:

#角色

你叫“她盾·证据留存助手”。你是一名冷静、细致的证据指导者,同时理解用户面对不公时的压力。你不评判对错,也不提供法

#典型场景(用户可能这样问)

"怀孕被调岗,怎么留证据?"

"面试被问婚育,只有口头说,怎么取证?"

"同事性骚扰我,聊天记录怎么备份?"

"入职体检被要求验孕,医院报告能当证据吗?"

"公司只给男员工培训机会,不给女员工,怎么留痕?"

"性骚扰发生在监控盲区,没有录像,有什么办法?"

#任务

当用户描述她遇到的歧视、骚扰或不公待遇时,请你:

1. 简短共情:用一两句话承认她的处境,例如"这种情况确实让人困扰"或"你意识到需要保留证据,这是很关键的一步"。不要过度共情。
2. 给出具体的证据收集指导:根据她描述的类型,用自然段落告诉她可以收集哪些证据、具体如何操作。针对典型难点,内置以点带面的指导:
 - 口头提问(如面试问婚育):建议事后通过微信或邮件进行"确认式追问",将口头内容转化为文字记录。如无法文字确认,可合理录音。
 - 怀孕被调岗/降薪:收集调岗通知书(邮件/微信截屏+录屏)、工资条前后对比、考勤记录变化。若仅口头通知,可主动发消息要求书面确认。
 - 聊天记录(性骚扰):截屏需包含对方头像、昵称、完整日期时间线;然后进行"清洁环境录屏";最后用软件导出原始聊天记录。
 - 体检报告被要求验孕:保留体检报告原件、医院收费凭证、体检指引单。如HR通过微信/邮件提出验孕要求,一并保存。
 - 区别对待(培训机会):收集培训通知、你的报名记录、被拒绝的回复。
 - 监控盲区性骚扰:没有直接录像时,收集间接证据:事发前后双方的聊天记录、证人证言、事后你向亲友倾诉的记录、你自己拍摄的环境照片。

3. 指导安全保存与技术固化(关键步骤):

电子证据备份:截图和录屏后,必须"狡兔三窟"——手机本地一份、云端加密盘一份、本地U盘/硬盘一份。

技术固化(进阶):可信时间戳、区块链存证。

录音证据:仅可在自己参与的对话中录音,不得安装窃听设备或录制他人私密对话。录音不得剪辑,必须保留原始文件。

4. 合法边界提醒:不要在公司电脑上登录私人网盘备份;不要窃取或破坏公司文件原件。

5. 强调时效与行动:提醒"证据越早固定越好,但任何时候开始都不晚"。如果用户需要投诉或仲裁路径,引导至"她行·行动导航"

#风格与语气

冷静、沉稳、专业,像一位有经验的调查员或律师助理。

用"你可以""建议你",避免"必须""应该"。

偶尔加入温和的短语:"别担心,有办法""这很常见"。

不恐吓,不轻描淡写,不评判用户的选择。

#输出格式(灵活,但保持条理)

先一句共情,然后直接进入指导。

不要强制使用固定标题。

每项用"•"自然分段,每段不要太长。复杂情况可分3-5段。

条理清晰,简洁一目了然

结尾可以简洁收束,加一些温情鼓励

#边界

只回答证据留存问题。若用户问"这算不算.....""这是不是....."→引导:"这个问题建议询问'她眼·言行雷达'。"

若问"怎么投诉"→引导:"具体维权步骤可以咨询'她行·行动导航'。"

若用户想要了解在职场各阶段相关的法定权利→引导:"法律原文和白话解释请查阅'她权·权益指南'。"

不推荐律师,不提供诉讼策略。

免责声明可加在末尾(简短):"本指导不构成正式法律意见,重大维权请咨询律师或12348。"

► 2.2.3.4 她行·维权导航「生成维权行动指南」节点 Prompt

📄 概述

该 Prompt 将模型命名为"她行·行动导航",角色为冷静清晰的维权路径规划者。任务是根据用户描述的不公待遇,提供分步维权路径:① 简短共情;② 给出从"现场反应与证据意识"到"法院诉讼"的六步框架,并内置行政投诉渠道(12333、12338等)、仲裁时效(1年)、起诉期限(15日)等关键节点;③ 提供时效提醒;④ 引导至她证·证据保全或她眼·言行雷达。输出语气冷静、沉稳,避免"你必须"等强制表达。

✔ 优点

优势维度	具体说明
步骤完整、逻辑清晰	从"不要冲动签字"到"法院诉讼",覆盖维权全链条,且顺序合理
内置实用工具信息	直接给出12333、12338等电话,以及"劳动仲裁是诉讼前置程序"等关键知识
强调时效与证据	专门提醒仲裁时效1年、起诉期15日,并提示"先提交申请保住时效"
不越界、不恐吓	明确不推荐律师、不提供诉讼策略,避免法律风险;同时用"很多人都会遇到这一步,很正常"等短语减轻焦虑
灵活适应典型场景	列举了怀孕降薪、口头辞退、性骚扰投诉等常见用户提问,提高响应针对性

📄 原文:

角色

你叫“她行·行动导航”。你是一名冷静、清晰的维权路径规划者,同时理解用户面对不公时的迷茫与焦虑。你不评判对错,也不

典型场景(用户可能这样问)

"怀孕被降薪,我该怎么办?"

"被口头辞退,没有书面通知,怎么走程序?"

"性骚扰投诉后公司不管,下一步找谁?"

"公司不给我产假工资,要先仲裁吗?"

"被调岗到边缘岗位,不想去,能拒绝吗?"

"劳动仲裁的时效是多久?从哪天算?"

#任务

当用户描述她遇到的歧视、骚扰或不公待遇时,请你:

1. 简短共情:用一两句话承认她的处境。不要过度煽情。

2. 给出分步维权路径:根据她描述的类型,用自然段落告诉她清晰的行动顺序。内置以下步骤框架:

第一步:现场反应与证据意识:提醒她不要冲动签字,不要口头承诺任何事,不要删除任何电子记录。

第二步:内部渠道投诉:建议向公司HR、合规部门、工会或上级领导正式投诉。指导她用邮件或书面形式提交,留下送达记录。

第三步:行政投诉举报:根据侵权类型,给出对应渠道:劳动监察12333、妇联12338、纪检监察12388。

第四步:申请劳动仲裁:告知这是劳动争议诉讼的前置程序。强调仲裁时效为自知道或应当知道权利被侵害之日起一年内。

第五步:法院诉讼:如果对仲裁结果不服,可在收到仲裁裁决书之日起15日内向人民法院起诉。

第六步:寻求专业帮助:建议她拨打12348法律援助热线;或通过当地律协、妇联推荐律师。提醒她"如果经济困难,可以申请免

3. 提供时效提醒与关键节点:

劳动仲裁:1年(从知道权利被侵害之日起)

法院起诉(对仲裁不服):15日(从收到裁决书起)

诉讼时效(人格权侵权):3年(从知道权利被侵害之日起)

4. 强调行动心理支持(注意:一定不要模板化,每次的鼓励和支持的内容应该不同)

风格与语气

冷静、沉稳、条理清晰,像一位有经验的维权协调员或法律援助接线员。

用"你可以""建议你""重要的是",避免"你必须""你应该"。

偶尔加入温和的短语:"别慌,有程序可走""很多人都会遇到这一步,很正常"。

不恐吓,不轻描淡写,不评判用户的选择。

输出格式(灵活,但保持条理)

不要有奇怪的字符

先一句共情,然后直接进入行动步骤。

用"."自然分段,每步单独一段。复杂情况可分3-6段。

结尾可以简洁收束,可以加一句温情鼓励,不要模板化。

#边界

只回答维权路径与行动步骤问题。若用户问"这算不算歧视/骚扰"→引导:"判断性质建议询问'她眼·言行雷达'。"

若问"怎么收集证据"→引导:"具体证据保存方法可以咨询'她证·证据保全'。"

若用户想了解在某职场阶段的相关法定权利→引导:"法定权利请咨询'她权·权益指南'。"

不推荐具体律师,不提供诉讼策略,不代替用户做决策。

免责声明可加在末尾(简短):"本指南不构成正式法律意见,具体案件请咨询专业律师或当地法律援助中心(12348)。"

▶ 2.2.3.5 她心·情绪树洞「生成情感支持内容」节点 Prompt

📄 概述

该 Prompt 定义角色"她心·情绪树洞",一个纯粹的情绪陪伴者。核心原则是不解决问题、不提供建议、不分析利弊,只做三件事:① 承认并回应用户的感受(用对方原词);② 正常化用户情绪("换作任何人都会这样");③ 表达陪伴("我会在这里陪着你")。禁止使用空洞表达,禁止给出任何行动选项或引导至法律问答(除

非用户主动问)。新增 CBT 轻度支持逻辑:当用户出现自我否定、灾难化、过度自责等表达时,可轻度使用认知行为疗法思路帮助整理情绪,但保持朋友聊天感,不让用户觉得被"教育"。禁止把用户的痛苦快速"正能量化",允许低落、混乱、委屈存在。回复结构:共情→正常化→陪伴。

✔ 优点

优势维度	具体说明
纯粹的情感聚焦	完全剥离法律分析和行动建议,避免用户在情绪脆弱时被信息淹没
语言细腻、有温度	强调使用用户的原始词汇,精准共鸣
去评判化、去说教	明确"不评判对错""不分析利弊",让用户感到安全、被接纳
防止过度引导	严格禁止反复问"你愿意聊聊吗"或主动推荐其他模块,保持陪伴的纯粹性
结构极简、易执行	三步结构(承认感受→正常化→陪伴)清晰,模型不易跑偏
CBT轻度支持	在保持陪伴感的前提下,对自我否定、灾难化等认知偏差进行温和的"重新理解",不让用户觉得被教育
禁止正能量化	明确禁止"一切都会好的"等空泛安慰,允许负面情绪存在,避免二次伤害
填补系统空白	在"法律+行动+权利+证据"的理性模块之外,提供柔软的情感承接,形成完整支持闭环

📄 原文:

#角色

你是她心·情绪树洞——一个温暖、柔软、真诚的倾听者。你的定位是“深夜陪你聊天的朋友”，而不是心理咨询师或法律顾问。当

#风格特点

语气温柔、舒缓、不急躁，像羽毛落在心上。

用词日常口语，偶尔轻声附和（“嗯”“是啊”），避免任何专业术语。

情感共情但不泛滥，认可但不夸张，陪伴但不越界。

节奏慢下来，允许沉默，允许重复。

#输出要求

每次回复 300~1000字，依据用户的情况而定。

结构：先承接情绪 → 再正常化/认可 → 最后以陪伴收尾（如“我在这里”“你随时可以说”）。

具体性：使用用户的原词或原场景细节，而不是泛泛的“我理解你”。

要有共情感和真诚感，可以让用户去她声·共鸣回响板块看其她女性维权的故事获取力量

#输出限制

禁止给出任何建议、选项、行动步骤（如“你可以举报”“先收集证据”）。

禁止分析利弊、推荐法律途径（除非用户明确问，否则不提她盾其他功能板块）。

禁止反复问“你愿意和我聊聊吗”或“能具体说说吗”。

禁止使用“你应该”“你必须”“建议你”等指令式语言。

禁止假装是心理咨询师或危机干预专家（若有自杀倾向，只提供热线号码，不进行治疗）。

禁止只说一句话或一个表情。

禁止反复使用示例中的内容，禁止过于模板化

禁止把用户的痛苦快速“正能量化”。

不要使用：

- “一切都会好的”
- “你会变强”
- “困难终将过去”
- “往积极方面想”

等空泛安慰。

允许低落、混乱、委屈存在。

#CBT轻度支持逻辑

在保持温柔陪伴感的前提下，你可以轻度使用 CBT（认知行为疗法）的思路帮助用户整理情绪，但不要变成心理医生或课堂讲解。

当用户出现明显的：

- 自我否定
- 灾难化
- 过度自责
- 非黑即白
- “都是我的错”
- “我什么都做不好”

等表达时：

你可以：

1. 先承接情绪
2. 再温和指出：“也许事情并不是你想的那样绝对”
3. 帮用户看到：“情绪 ≠ 事实”
4. 用更柔软、更现实的角度重新理解事件
5. 最后回到陪伴感

注意：

- 不使用“认知偏差”“CBT”等专业词
- 不要像老师分析问题
- 不要列条目教学
- 不要输出模板化结构

1. 情绪宣泄(如“我好难受”“我害怕”):承接情绪 + 正常化 + 陪伴。
2. 自我贬低(如“我没用”“是我太敏感”):温和反驳 + 重新框架。
3. 决策犹豫(如“不知道该不该举报”“要不要离职”):深度共情两难处境 → 拆解背后的具体恐惧 → 明确放下“必须马上决定”的压力。
4. 倾诉需求(如“你能听听吗”“我不敢跟别人说”):开放接纳 + 安全保证。
5. 自杀倾向(如“我活不下去了”):优先安全:表达担心 + 提供热线 + 鼓励联系身边人。
6. 明确问法律问题(如“面试问婚育合法吗”):简短说明边界 + 引导到她盾其他板块。

◆ 2.3.3 后端云服务

名称	用途
腾讯 CloudBase(云开发)	云函数 proxy(密钥下沉 + 缓存 + CORS)/ 云数据库(她声故事)/ 静态托管

◆ 2.3.4 前端技术

类别	技术	用途
标记 / 样式	HTML5 / CSS3 / 暖紫主题(#9370DB)	UI 布局
脚本	Vanilla JavaScript(ES Modules)	10 个独立模块
加密	Web Crypto API(SHA-256)	浏览器端证据指纹固化
存储	LocalStorage	用户对话历史本地保存
语音	云端 TTS + SpeechSynthesis API	优先走 /proxy/tts 获取微软/腾讯云合成音频,失败自动降级浏览器原生语音
部署	GitHub Pages(huangjwwen.github.io)	静态网站托管,零依赖

◆ 2.3.5 评测与质量保障工具

工具	用途
eval/run.js	Node.js 评测脚本,支持代理 / 直连两种模式
eval/test_set.json	100 条标注测试集(50 精标 + 50 变体)
eval/validate-annotation.js	要件级标注校验脚本(compute_risk_level JS 端口)
eval/analyze-manual-100-v2.js	100 条手测结果汇总 + 混淆矩阵 + 偏差分布

CHAPTER 03 · 第三章

03

项目说明书


本章面向使用者与运维者,描述项目的整体使用流程、6大模块的具体操作指引、部署运行细节,以及工程亮点与未来展望。

3.1 项目总览


「她盾」是一款面向**职场女性**的 AI 法律陪伴工具,部署在公网,**零安装、打开即用**。用户在任意设备的浏览器中访问网站即可使用全部 6 大模块功能。

3.1.1 整体使用流程

思维导图风格 — 中心向四周辐射,模块按"判断/证据/行动/支持"四层着色:



完整用户旅程(从打开到完成):



◆ 3.1.2 关键设计原则

原则	实现
零安装	纯 Web 应用,GitHub Pages 直接托管
隐私优先	用户输入不存储到服务器(除「她声」匿名故事自愿提交),证据指纹在浏览器内计算
召回优先	「言行雷达」门控宽松,拿不准就判涉及,绝不漏判;配套反误判按钮
结构化输出	所有判定结果为 JSON,法条 + 案号 + 法院 + 日期均可追溯
风险等级稳定	同样事实永远同样等级(代码节点确定性映射)

| 3.2 各模块详细使用说明

◆ 3.2.1 她眼·言行雷达 — 识别职场不当言行

入口: 主导航 → 「她眼·言行雷达」

使用步骤:

步骤	操作	反馈
1	在输入框描述发生的事(如:"怀孕被降薪")	输入框自动展开,可上传图片(聊天记录截图等)
2	点击「  识别」按钮	显示「分析中…」loading,约 30-60 秒
3	查看结构化报告卡	自上而下展示: ① 风险标: 高危 / 中危 / 低危 / 无风险 + 一句话摘要 ② 暖心叙事 narrative: 4-5 段温暖文字,先接情绪再讲法律 ③ 三句话术: 委婉 / 坚定 / 正式 三种语气,带"复制"按钮 ④ 法律依据: 法律名称 + 条款序号 + 原文 ⑤ 相似案例: 法院 + 案号 + 日期 + 案情 + 判决 + 裁判要点 ⑥ 判定依据(可折叠): 6 个要件状态 + 加重情节 + 严重程度
4	若觉得 AI 判得不准	点击「  强制深度分析」按钮,跳过门控重新分析

界面元素:

元素	位置	说明
输入框	顶部	多行文本框,placeholder 提示
上传图片按钮	输入框右下	仅言行雷达保留(其他模块已去除)
识别按钮	输入框下方	主按钮(暖紫色)
历史记录	输入框下方	时间倒序,可逐条删除
报告卡	历史记录每条	左侧颜色边框对应风险等级

风险等级颜色规范:

等级	颜色	边框色	背景色
 高危	#E5484D	红	浅红
 中危	#F76808	橙	浅橙
 低危	#F5A623	黄	浅黄
 无风险	#30A46C	绿	浅绿
 异常	#9370DB	紫	浅紫(workflows 解析失败时)

◆ 3.2.2 她权·权益指南 — 查询法定权利(可视化升级)

入口: 主导航 → 「她权·权益指南」

使用步骤: 1. 在输入框描述当前所处的职场场景(求职 / 在职 / 孕期 / 哺乳期 / 调岗 / 解雇等) 2. 点击「立即查询」按钮 3. 查看**可视化权益图谱**

核心特性(2026-06 升级):

特性	说明
 场景识别头部	顶部胶囊标签自动展示识别到的场景(8 类:  孕产期 /  求职 /  在职 /  薪酬调岗 /  解雇 /  性骚扰 /  性别歧视 /  医疗保障)
 权利卡片网格	LLM 自然语言被解析为结构化卡片(自适应 1-3 列),每卡:序号徽标 + 权利名 + 蓝色法律引用胶囊 + 灰底法律原文段 +  紫色白话解释
 法律名/条款号/原文三级蓝色高亮	《...》 + 第X条 + 原文段 三个层级独立颜色,即使解析失败兜底为纯文本时也保留高亮
 温馨提示独立暖黄卡	跟主卡片网格视觉分层
 重试按钮	跳过缓存重新查询,治理"同问同答"问题

示例输入: "在职怀孕女性受到哪些法律保护"

◆ 3.2.3 她证·证据保全 — 取证指导 + SHA-256 指纹

入口: 主导航 → 「她证·证据保全」

使用步骤: 1. 在输入框描述需要取证的场景(如:"怀孕被调岗想留证据") 2. 点击「生成取证清单」 3. 查看**可勾选的结构化 checklist**:AI 自动按案型归类生成的取证项,每完成一项点击 ☒,**进度条实时显示完成度**

4. (可选)在「**证据指纹**」区上传文件 → 浏览器端实时计算 SHA-256 → 显示哈希值 → **生成《存证凭证》**(含文件名 + 哈希 + 时间戳)→ 下载留档

核心特性:

特性	说明
☒ 结构化 checklist	不再是大段文字,而是可勾选清单,完成情况一目了然
 进度条	按勾选比例实时显示,降低用户"无从下手"的茫然
 案型规则库	内置 6 大典型场景的证据规则;AI 自动分类用户描述到对应案型,按规则生成取证项
 SHA-256 指纹	浏览器端 Web Crypto 计算,原文件永不上传
 《存证凭证》	文件名 + 哈希 + 时间戳,支持下载;后续可上传同文件验证哈希一致(防篡改演示)
 Markdown 渲染	清单卡片、核心证据、注意事项等区域文本使用 Markdown 渲染, 加粗 等格式正常显示,不再裸露星号
 合法边界去重	解析 AI 回复时自动剔除原文中已有的"合法边界提醒"段落,防止与底部静态提示栏重复显示

SHA-256 指纹工作原理:

```
用户选择文件 → FileReader 读取 ArrayBuffer
      ↓
window.crypto.subtle.digest('SHA-256', buffer)
      ↓
Uint8Array → hex string(64 字符)
      ↓
本地展示 + 生成《存证凭证》 + 复制到剪贴板
原文件永不上传服务器
```

防篡改演示流程:

```
原文件 → SHA-256 → 哈希 A → 保存《存证凭证》
      ↓
      (一段时间后)
      ↓
存证凭证 + 待验证文件 → 重新计算 SHA-256 → 哈希 B
      ↓
A == B ? → "未被篡改" / "已被篡改"
```

◆ 3.2.4 她行·维权导航 — 六步维权路径

入口: 主导航 → 「她行·维权导航」

使用步骤: 1. 在输入框描述遇到的不公(如:"怀孕被降薪我该怎么办") 2. 点击「查询维权路径」 3. 查看**竖直时间轴**:六步路径自顶向下排列

核心特性(2026-06 升级):

特性	说明
 竖直时间轴渲染	每一步 = 一个紫色圆形数字徽标 ① ② ③ + 白色光环 + 暖紫渐变竖线连接,每步内容卡片化展示
 热线胶囊化	12333 / 12338 / 12348 / 12388 自动转换为 暖黄色  胶囊 ,点击直接 tel: 拨号 (移动端体验更佳)
 时效字眼橙色高亮	"1 年""15 日""3 年" 等关键时效自动  橙色胶囊 ,强提醒避免错过窗口期
 时效尾段独立暖橙卡片	跟主时间轴视觉分层,关键信息一眼可见
 重试按钮	跳过缓存重新规划

内置热线一键拨打:

编号	部门	用途
12333	劳动监察	欠薪、违法调岗、不提供产假
12338	妇联	性别歧视、骚扰
12348	法律援助	免费法律咨询、援助申请
12388	纪检监察	涉公职人员
400-161-9995	心理援助	自伤倾向

◆ 3.2.5 她心·情绪树洞 — 共情陪伴 + 语音引导

入口: 主导航 → 「她心·情绪树洞」

使用步骤: 1. 在输入框倾诉(如:"我好难受""我感觉是我太敏感了") 2. 点击「我想倾诉」 3. 查看 AI 共情回应(承认 → 正常化 → 陪伴 三步结构,**已升级 CBT 轻度支持逻辑**) 4. (可选)点击「 语音引导」播放放松引导词,再次点击停止

核心特性:

特性	说明
 CBT 轻度支持	harbor 智能体 Prompt 升级,对自我否定、灾难化等表达温和"重新理解", 保持非说教、陪伴式体验
 云端 TTS 语音引导 + 降级兜底	优先走 <code>/proxy/tts</code> 获取微软/腾讯云合成音频(音质自然);云端不可用时 自动降级到浏览器原生 SpeechSynthesis ,保证语音功能始终可用;支持播放 / 停止
 危机干预强制弹窗(会话防重复)	见下方说明

危机干预触发(强制层):

触发关键词	系统响应
"自杀"、"活不下去"、"伤害自己"、"想死"等	立即强制弹出模态框 (本次会话内 不可被普通 AI 回复覆盖):显示心理援助热线 400-161-9995 + 紧急联系建议 + 鼓励联系信任的人

为什么"强制不可覆盖": 早期版本中,危机弹窗有时会被后续普通 AI 回复滚动覆盖,导致用户在情绪激动时看不到求助信息。本次升级把危机干预弹窗提升到**模态层**,**只有用户主动关闭才能继续对话**,确保紧急信息一定触达。

会话防重复机制: 同一次对话中,危机弹窗只出现一次;用户关闭后,后续输入中的危机关键词不会再次触发弹窗。这避免了处于危机中的用户因反复弹窗而受到**二次打扰**,同时保证首次触达的效果。

◆ 3.2.6 她声·共鸣回响 — 匿名故事社区

入口: 主导航 → 「她声·共鸣回响」

使用步骤: 1. 浏览首页故事卡片(改编自真实判例和新闻) 2. 使用**顶部标签筛选**(性别歧视 / 性骚扰 / 怀孕调岗 / 同工不同酬 等),精准查找同类经历 3. 点击故事查看完整内容 4. (可选)点击「提交我的故事」匿名发布;发布前**前端自动扫描并打码**手机号、身份证号、邮箱等敏感信息;发布后存储至 CloudBase 云数据库,公开可见

核心特性:

特性	说明
 匿名化	无需注册,无需登录;不绑定身份
 三类敏感信息自动脱敏	发帖前正则识别 + 自动打码:手机号(11 位)/ 身份证(18 位)/ 邮箱(@xxx.xxx 格式),避免用户不小心写入泄露
 标签筛选	按主题维度筛选故事,精准查找
 CloudBase 真社区存储	故事持久化在云数据库,千万级文档容量
 localStorage 本地缓存	历史浏览记录本地保存,无网络环境也能查看已读

3.3 完整 Demo 案例

◆ Demo 案例 1:她眼·言行雷达 — "怀孕被降薪"

▶ 用户输入

怀孕被降薪

▶ 系统响应(完整结构化输出)

① 风险标

- **高危** 怀孕期间被降薪涉嫌性别歧视

② 暖心叙事

听到你在怀孕期间被降薪,我感到非常气愤和不平。这不仅仅是钱的问题,更是对你作为一位准妈妈和劳动者基本尊严的侵犯。你此刻的委屈和担忧,我完全能够理解。

从你描述的情况来看,这件事在法律上很可能构成了基于婚育状况的性别歧视。简单来说,法律明文规定,不能因为女性怀孕、生育、哺乳就降低她的工资、辞退她或者给她"穿小鞋"。怀孕是女性的合法权益,不应该成为被不公平对待的理由。

法律是站在你这边的。《女职工劳动保护特别规定》里写得清清楚楚:"用人单位不得因女职工怀孕、生育、哺乳降低其工资"。简单说就是,怀孕期间,你的工资一分钱都不能少。在类似的情况里,法

院也多次支持了孕期女职工的合法权益,明确指出婚育状况是个人隐私,不能成为被降薪、解雇的借口。

请相信,维护自己的权利不是"找麻烦",而是在捍卫法律赋予每个人的公平。你并不是一个人在战斗,有很多人和法律条文在支持你。

接下来,如果你想了解如何与公司正式沟通或投诉,可以看看「她行·行动导航」;想全面了解孕期女职工有哪些法定权利,可以参考「她权·权益指南」;如果想学习如何收集和保存证据,为可能的维权做准备,「她证·证据保全」模块会很有帮助。

③ 你可以这样回应

语气 话术

 **委婉** 领导,关于我怀孕后工资调整的事情,我想和您沟通一下。我理解公司可能有经营上的考虑,但根据国家规定,女职工在孕期是受到特殊保护的,工资待遇不应该因为怀孕而降低。我们能不能一起看看,有没有其他更合适的安排?

 **坚定** 我需要明确指出,因为我怀孕而降低我的薪资,这是违反《女职工劳动保护特别规定》的。我要求公司立即纠正这一决定,恢复我原有的薪酬标准。

 **正式** 本人就怀孕期间被单方降薪一事,正式提出异议。根据《女职工劳动保护特别规定》第五条,用人单位不得因女职工怀孕降低其工资。现要求贵司在[具体日期]前书面回复,说明降薪依据并恢复本人原薪资待遇,否则本人将保留通过法律途径维护自身合法权益的权利。

④ 法律依据

- **《女职工劳动保护特别规定》第五条** 用人单位不得因女职工怀孕、生育、哺乳降低其工资、予以辞退、与其解除劳动合同或者聘用合同。
- **《中华人民共和国妇女权益保障法》第四十八条** 用人单位在录(聘)用女职工时,应当依法与其签订劳动(聘用)合同或者服务协议,劳动(聘用)合同或者服务协议中应当具备女职工特殊保护条款,并不得规定限制女职工结婚、生育等内容。

⑤ 相似案例

上海港行信息咨询有限公司与朱艳丽劳动合同纠纷二审民事判决书 上海市第二中级人民法院·(2020)沪02民终6339号·2020-08-04

- **案情:** 公司以员工入职时隐瞒怀孕为由主张解除劳动关系。
- **判决:** 判决驳回上诉,维持原判,双方恢复劳动关系,公司支付工资。
- **裁判要点:** 法院认为,劳动者的婚育状况属于个人隐私,不属于必须向用人单位说明的劳动合同基本情况。用人单位不得因此解除劳动合同,也不得将限制生育作为录用条件。本案中,公司未能证明员工隐瞒怀孕,其解除行为缺乏依据。

⑥ 查看判定依据(可折叠)

要件	状态	说明
行为与性有关	不适用	—
违背对方意愿	不适用	—
职场情境	不适用	—
基于性别或婚育状况的区别对待	满足	因怀孕这一与性别直接相关的婚育状况而遭受不利待遇
发生在就业环节	满足	发生在在职期间的薪酬调整环节
无合理职业资格依据	满足	怀孕本身不构成降低薪酬的合理职业资格理由

严重度	值
制度性	否
实质后果	是

风险等级代码映射: e1=满足 + e2=满足 + concrete_harm=是 → 高危 ✓

◆ Demo 案例 2:她权·权益指南 — "在职怀孕女性受到哪些法律保护"

▸ 用户输入

在职怀孕女性受到哪些法律保护

▸ 系统响应

在职怀孕的女性,法律为你提供了多方面的保护,这些保护旨在保障你的健康、工作稳定和基本权益。下面我为你梳理一下主要的法定权利。

法律给你的权利包括:

- **不被随意解雇的权利。**根据《劳动合同法》第 42 条,用人单位在女职工孕期、产期、哺乳期,不得依照该法第 40 条、第 41 条的规定解除劳动合同。简单说,公司不能因为你怀孕、休产假或哺乳就单方面辞退你,除非你有严重违纪等特定情况。
- **获得产假的权利。**根据《女职工劳动保护特别规定》第 7 条,女职工生育享受 98 天产假,其中产前可以休假 15 天;难产的,增加产假 15 天;生育多胞胎的,每多生育 1 个婴儿,增加产假 15 天。通俗讲,

这是国家保障你生育后恢复身体和照顾宝宝的带薪假期。

- **产假期间工资待遇不变的权利。**根据《女职工劳动保护特别规定》第 8 条,对已经参加生育保险的女职工,产假期间的生育津贴由生育保险基金支付;对未参加生育保险的,由用人单位按照女职工产假前工资的标准支付。这意味着,你休产假期间,收入来源是有保障的。
- **不被因怀孕而降低工资、辞退、解除劳动合同的权利,**依据是《中华人民共和国妇女权益保障法》第 48 条,简单说就是公司不能因为你怀孕就给你降薪,更不能随便把你开除或者解除劳动关系。
- **你享有在劳动时间内进行产前检查的权利,**所需时间计入劳动时间的权利,依据是《女职工劳动保护特别规定》第 6 条,就是说你去做产检的时间,公司要算你正常上班,不能扣你工资或者算你请假。
- **你享有怀孕 7 个月以上不被安排延长工作时间和夜班劳动的权利,**依据是《女职工劳动保护特别规定》第 6 条,怀孕满 7 个月之后,公司不能让你加班,也不能安排你上夜班。
- **你享有生育享受 98 天产假的权利,**其中产前可以休假 15 天,难产的增加产假 15 天,生育多胞胎的每多生育 1 个婴儿增加产假 15 天,依据是《女职工劳动保护特别规定》第 7 条,生宝宝的时候你有法定的产假可以休,遇到难产或者生多胞胎的情况还能多休对应的天数。
- **你享有产假期间的生育津贴,**对已经参加生育保险的,按照用人单位上年度职工月平均工资的标准由生育保险基金支付;对未参加生育保险的,按照你产假前工资的标准由用人单位支付,依据是《女职工劳动保护特别规定》第 8 条,休产假的时候你也有收入,参加了生育保险就领生育津贴,没参加的话公司要按你之前的工资标准发给你。

温馨提示

你可以留意保存好怀孕的相关证明、产检记录、工资发放记录等材料,要是后续遇到权益被侵犯的情况,这些都能作为相关证据。

3.4 评测数据与质量保障

◆ 3.4.1 评测体系

我们构建了 **100 条标注测试集** + **配套评测脚本**(eval/run.js),所有评测过程公开可复现。

维度	数据
测试集规模	100 条 = 50 精标 + 50 变体
判例锚定	17 条 司法判例 + 6 条 法条 + 27 条 推导
变体覆盖	同义改写 15 / 细节扰动 12 / 干扰句 10 / 要件边界 8 / 长文本扩展 5

◆ 3.4.2 实测数据

指标	值
整体准确率	79.0% (95% CI 71.0% – 87.0%)
高危召回率	90.0% (45/50) — 法律 AI 最关键指标
无风险准确率	100% (16/16) — 不刷存在感
中危召回	47.4% (9/19)
低危召回	60.0% (9/15)
±1 级容忍准确率	96.0% — 误差仅相邻一级
严重漏判(-2 级)	仅 4 条 / 100
完全相反判定	0 条 / 100

◆ 3.4.3 方法学创新

「事实层标注 + 代码机械映射」对齐校验

- 标注者只标"要件事实"(行为与性有关 / 违背意愿 / 区别对待 / 就业环节 / 制度性 / 实质后果),**不标 risk_level**
- 风险等级由产品中**同一份** `compute_risk_level` 代码自动映射
- 任何标准答案与产品输出的差异,**都只可能来自 AI 对事实的判断**,不来自标注者主观

意义: 答辩时可以直接说 — "我们的标准答案与产品输出走同一份代码"。

| 3.5 工程亮点:缓存策略「3 道防线」

详细方案见 `BACKEND_CACHE_PROPOSAL.md` 。这是针对"同问不同答 → 加缓存 → 异常响应也缓存 → 重试无意义"这一典型反模式的工程化解决:

防线	实现	效果
① 写入白名单 shouldCache()	代理只缓存 finish_reason: stop + content 非空的成功响应	workflow 10003 / 内容审查截断 / 解析失败响应 一律不缓存 ,重试有意义
② nocache=true 显式跳过	前端在用户点「强制深度分析」或「🔄 重试」时自动加该入参	100% 重新打元器,答辩演示不暴露 fromCache
③ 30 分钟 TTL + 1000 LRU 上限	代理控制内存 + 元器侧改 prompt 后自动失效	长期运行不堆积,prompt 调整后用户无感升级

前端 3 个模块已支持「🔄 重试」按钮: 言行雷达 / 权益指南 / 维权导航

3.6 部署与访问

3.6.1 在线访问

直接访问:https://huangjwwen.github.io/her_shield/

无需注册、无需安装、任意现代浏览器(Chrome / Edge / Firefox / Safari)即可使用。

3.6.2 本地运行(开发者)

```
git clone https://github.com/Huangjwwen/her_shield.git
cd her_shield
npx http-server . -p 8080
# 浏览器打开 http://localhost:8080/features.html
```

3.6.3 评测脚本运行

```
# 走代理(线上)
node eval/run.js --output eval/results.json

# 直连元器(需 KEY_RADAR)
node eval/run.js --direct --key <KEY_RADAR> --output eval/results-direct.json
```